| In [ ]:            | 1- Imports %load_ext autoreload  |
|--------------------|--|
|                    | %autoreload 2 import pandas as pd import matplotlib.pyplot as plt  2- Fouille de données   |
|                    | <pre>FILE = '/data/raw/providers.csv' df = pd.read_csv(FILE)  df.shape</pre>   |
| Out[ ]:            | (227, 10)  df.head(10)   |
| Out[ ]:            | idcompany_idprovider_idnamefullnamehas_plughas_adjustable_seatshas_bicycletransport_type091NaNouibusOuibusTrueTrueFalsebus1102NaNdeinbusDeinbus.deFalseFalseFalsebus   |
|                    | 2 11 3 NaN infobus Infobus False False False bus 3 12 4 NaN studentAgency Student Agency False False False bus 4 13 5 NaN flixbus Flixbus True False False False bus   |
|                    | 5146NaNdriivmeDriiveMeFalseFalseFalsecar6158NaNalsaAlsaFalseFalseFalsebus7169NaNdistribusionDistribusionFalseFalseFalsebus9171818FalseFalseFalsebus  |
| In [ ]:            | 8 17 9 31 expressbusMunchen Expressbus Munchen False False False bus 9 18 9 33 berlinLinienBus Berlin Linien Bus False False False bus  df.dtypes  |
| Out[ ]:            |  |
|                    | has_wifi object has_plug object has_adjustable_seats object has_bicycle object transport_type object   |
| In [ ]:<br>Out[ ]: | <pre>dtype: object  df.isna().any()</pre>  |
|                    | provider_id True name False fullname False has_wifi True has_plug True   |
|                    | has_adjustable_seats True has_bicycle True transport_type False dtype: bool  |
| Out[ ]:            | <pre>sorted(df.company_id.unique()), df.company_id.nunique() ([1, 2, 3, 4, 5, 6, 8, 9, 10, 11, 12, 20, 30, 40], 14)  df_companies = df.query('provider_id.isnull()')[['company_id', 'fullname']]</pre>   |
|                    | <pre>print (df_companies)  company_id fullname  0    1    Ouibus  1    2    Deinbus.de  2    3    Infobus</pre>  |
|                    | 4 Student Agency 5 Flixbus 6 DriiveMe 7 Distribusion   |
|                    | 208       10       Voyages SNCF         212       20       Transdev         223       11       Blablacar         224       30       Vatry         225       40       Beauval         226       12       idVroom  |
| In [ ]:            | <pre>df_groupby_count_providers = df.groupby('company_id')['provider_id'].nunique() df_to_plot = df_companies.join (df_groupby_count_providers, on=['company_id']) ax = df_to_plot.plot(kind='barh'</pre>  |
|                    | <pre>, y='provider_id' , figsize= (10,10))  ax.set_xlabel('Nombres de transports') ax.set_title('répartition des sous- compagnies en fonction des compagnies') ax.bar_label(ax.containers[0])</pre>  |
|                    | plt.show()  répartition des sous- compagnies en fonction des compagnies  idVroom -0  provider_id   |
|                    | Beauval -0 Vatry -0  |
|                    | Blablacar -0 Transdev - 3  |
|                    | Voyages SNCF - 10  Distribusion - 200  Alsa -0   |
|                    | DriiveMe -0 Flixbus -0   |
|                    | Student Agency -0 Infobus -0   |
|                    | Deinbus.de -0  Ouibus -0  0 25 50 75 100 125 150 175 200  Nombres de transports  |
| In [ ]:            | <pre>Mombres de transports  df_groupby_transport_type = df.groupby('transport_type')['company_id'].nunique() ax = df_groupby_transport_type.plot(kind='pie'</pre>  |
|                    | <pre>, title='Distribution du type de service' , ylabel='' , xlabel='' , autopct='%.2f' ) plt.show()</pre>   |
|                    | Distribution du type de service  |
|                    | bus  |
|                    | 73.33  |
|                    | 6.67   |
|                    | 13.33 train  |
|                    | carpooling   |
|                    | car  |
| In [ ]:            | <pre>df_groupby_count_transport_type = df.groupby('transport_type')['transport_type'].count()  ax = df_groupby_count_transport_type.plot.barh(figsize = (10,10))  ax.set_xlabel('Nombres de transports') ax.set_title('Nombres de transports en fonction du type')</pre>   |
|                    | ax.bar_label(ax.containers[0]) plt.show()  Nombres de transports en fonction du type   |
|                    | train - 10   |
|                    |  |
|                    | carpooling - 2   |
|                    | car - 1  |
|                    |  |
|                    | bus -  |
| In [ ]:            | 0 25 50 75 100 125 150 175 200  Nombres de transports  df_copy = df.copy() dict_to_replace = {}  |
| In [ ]:            | <pre>for i in df_companies['company_id']:     dict_to_replace[i] = df_companies.loc[df_company_id'] == i].fullname  df_copy = df_copy.replace ({'company_id':dict_to_replace})  df_groupby_count_company_transport = df_copy.groupby(['company_id', 'transport_type'])['transport_type'].count()</pre>   |
| In [ ]:            | <pre>ax = df_groupby_count_company_transport.unstack().plot(kind='bar'</pre>   |
|                    | plt.show()  Répartition des types de transport en fonction des compagnies  |
|                    | bus  200 - 150 -   |
|                    | 100 -<br>50 -<br>Car   |
|                    | 0.75 -<br>0.50 -   |
|                    | 0.25 - 0.00 - carpooling   |
|                    | 0.75 - 0.50 - 0.25 - 0.00 carpooling   |
|                    | 0.00 train 7.5   |
|                    | 2.5 - Alsa Beauval Blablacar Deinbus de Deinbus Drivente Flixbus Infobus Ouibus Agency Latry Agency Latry La |
| In [ ]:            | fig, ax = plt.subplots(figsize=(10, 10)  |
| [ ]·               | <pre>, nrows=2 , ncols=2) axe = ax.ravel() titles = ['Has wifi ?', 'Has Plug ?', 'has adjustable seats ?', 'Has bicycle ?'] for i, column in enumerate(['has_wifi', 'has_plug', 'has_adjustable_seats', 'has_bicycle']):</pre>   |
|                    | <pre>df_copy[column].value_counts().plot(kind='pie'</pre>  |
|                    | plt.show()  Has wifi?  Has Plug?   |
|                    | False 00 21  |
|                    | False 98.21 179 True False 98.66 1.34 True   |
|                    | has adjustable seats ? Has bicycle ?   |
|                    |  |
|                    | False 94.64 False 7.36 False 7.36 False 7.45   |
|                    |  |
| In [ ]:            | <pre>df_duplicated = df[df.duplicated(["fullname","has_wifi","has_plug","has_adjustable_seats","has_bicycle","transport_type"], keep=False)] print (df_duplicated)  id company_id provider_id</pre>  |
|                    | 215 8377 10 2 corailintercité Intercités False 218 8380 10 5 train TER False 221 8383 10 9 corail Intercités False  has_plug has_adjustable_seats has_bicycle transport_type   |
|                    | 213 False True False train 215 False True False train 218 False True False train 219 False True False train 210 False True False train   |
|                    | <ul> <li>Analyses</li> <li>id : identifiant</li> <li>company_id : identifiant de la compagnie</li> <li>provider_id : identifiant de la sous compagnie</li> </ul>   |
|                    | <ul> <li>provider_id : identifiant de la sous compagnie</li> <li>name : nom</li> <li>fullname : nom officiel</li> <li>has_wifi : wifi présent ou non</li> <li>has plug : prise présente ou non</li> </ul>  |
|                    | <ul> <li>has_plug : prise présente ou non</li> <li>has_adjustable_seats : siège ajustable ou non</li> <li>has_bicycle : porte vélo ou non</li> <li>transport_type : type de transport</li> </ul>   |
|                    | Lorsque une ligne contient un company_id et pas de provider_id, il s'agit de la compagnie qui englobe des sous-compagnies.  Il y a 14 compagnies:  [Ouibus, Deinbus.de, Infobus, Student Agency, Flixbus, DriiveMe, Alsa, Distribusion, Voyages SNCF, Transdev, Blablacar, Vatry, Beauval, idVroom]  Distribusion détient plus de 90% des sous compagnies. Le reste est partagé avec Voyage SNCF et Transdev.  |
|                    | Distribusion détient plus de 90% des sous compagnies. Le reste est partagé avec Voyage SNCF et Transdev.  Près de 94% des transports sont des bus.  73% des compagnies proposent des bus comme moyen de locomotion.  On remarque des monopoles : bus (Distribusion), car (DriiveMe) et train (Voyages SNCF)  Le carpooling est partagé entre IdVroom et Blablacar.   |
|                    | Le carpooling est partagé entre IdVroom et Blablacar.  Parmi les providers, on remarque la présence de 2 doublons : TER et Intercités. D'après le nom donné à ces doublons, il se peut que certaines données proviennent de différentes sources, ce qui expliquerait la multiplication de noms pour un même provider.  Data Preparation  |
| In [ ]:<br>In [ ]: | Data Preparation  df_copy = df_copy.drop_duplicates(subset=["fullname", "has_wifi", "has_plug", "has_adjustable_seats", "has_bicycle", "transport_type"])  df_copy.to_csv('/data/cleaned/providers_cleaned.csv')   |
| r 1.               |  |